



PROJET DE STAGE D'ETE

Présenté à

**L'Ecole Nationale d'Electronique et des Télécommunications de
Sfax**

Génie des Systèmes Electronique de Communication

Par

Ghazi Abdallah

Classification des maladies des blés

M. Mouna Dammak	Encadrante du CRNS
-----------------	--------------------

Année Universitaire : 2022-2023

Remerciement

C'est avec un grand plaisir que je réserve ces quelques lignes en signe de gratitude et de reconnaissance à tous ceux qui ont contribué de près ou de loin à l'élaboration de ce travail.

*Ma gratitude et ma reconnaissance s'adresse également à notre encadrante académique « **M. Mouna Dammak** », pour son encadrement, son dévouement, son soutien, sa disponibilité et ses conseils qui nous ont guidés tout au long de ce projet.*

Enfin une pensée particulière à tous nos enseignants de l'ENET'COM et à tous ceux qui ont participé à notre formation. Qu'ils trouvent ici l'expression de notre gratitude et de notre profond respect.

TABLE DES MATIERES

INTRODUCTION GENERALE.....	7
CHAPITRE 1 : PRESENTATION DU PROJET ET ETAT DE L'ART.....	8
I. Introduction.....	9
II. Présentation générale du CRNS.....	9
III. Présentation du projet	10
III.1 Contexte.....	10
III.2 Problématique.....	10
III.3 Objectifs.....	10
III.4 Systèmes existants.....	11
IV. Etat de l'art :	11
IV.1 Intelligence Artificielle	11
IV.2 Apprentissage Automatique	11
IV.3 Apprentissage Profond.....	12
IV.4 Classification Des images par apprentissage profond.....	13
IV.4.1 Introduction.....	13
IV.4.2 Définition de l'image.....	13
IV.4.3 Différents types de classification des images.....	14
IV.4.4 Quelques méthodes de classification des images.....	14
Classification via CNN.....	14
Classification via Transfert Learning.....	15
IV.4.5 Indicateurs de performance en classification.....	16
Matrice de confusion.....	16
Rapport de classification.....	17
IIV. Conclusion.....	18

CHAPITRE 2 : REALISATION DU PROJET :	19
I. INTRODUCTION.....	20
II. BIBLIOTHEQUES UTILISEES.....	20
II.1 TensorFlow.....	20
II.2 Keras.....	20
II.3 Python.....	20
III. APPRENTISSAGE DU MODELE.....	21
III.1 La base de données.....	21
III.2 Implémentation des algorithmes d'apprentissages.....	21
III.3 Problèmes lors de l'apprentissage.....	22
III.4 Augmentation des données.....	23
III.5 Impact du taux d'apprentissage.....	24
III.6 Impact de la taille du lot.....	24
III.7 Comparaison des modèles utilisées.....	25
IV. RESULTAS FINALES.....	25
IV.1 Architecture du modèle optimal.....	25
IV.2 Paramètres.....	27
IV.3 Courbes obtenues.....	27
IV.4 Rapport de classification.....	28
IV.5 Matrice de confusion.....	28
V. Conclusion.....	29
CONCLUSION GENERALE ET PRESPECTIVES	30
BIBLIOGRAPHIE	31

LISTE DES FIGURES :

- Figure 1 : Centre de recherche en numérique Sfax
- Figure 2 : Intelligence artificielle
- Figure 3 : Types d'apprentissage automatique
- Figure 4 : Architecture d'apprentissage profond
- Figure 5 : Types des images numériques
- Figure 6 : Apprentissage supervisé et non supervisé
- Figure 7 : Principe du modèle CNN
- Figure 8 : Architecture VGG19
- Figure 9 : Matrice de confusion
- Figure 10 : Logo TensorFlow
- Figure 11 : Logo Keras
- Figure 12 : Logo Python
- Figure 13 : Logo Google Colaboratory
- Figure 14 : Précision perturbée et faible
- Figure 15 : Perte perturbée et faible
- Figure 16 : Précision d'évaluation faible
- Figure 17 : Explication taux d'apprentissage
- Figure 18 : Explication taille du lot
- Figure 19 : Précision du train et test VGG19
- Figure 20 : Perte du train et test VGG19
- Figure 21 : Rapport de classification VGG19
- Figure 22 : Matrice de confusion VGG19

INTRODUCTION GENERALE

En 2050, l'agriculture devra produire environ 50 % de nourriture en plus en raison de l'augmentation de la population mondiale et du changement des régimes alimentaires (FAO, 2017).

La production de blé devrait augmenter, car il s'agit de l'une des principales cultures de base dans le monde, fournissant 20 % des calories et des protéines pour l'alimentation humaine (Tilman et al., 2011) ; cette croissance sera principalement basée sur l'augmentation des rendements, car il existe une forte concurrence pour les rares terres arables productives de la part d'autres secteurs de la société (FAOSTAT, 2020).

La demande future devra être atteinte par une croissance durable combinant une gestion intégrée des maladies et des ravageurs, une adaptation à des climats plus chauds et à une fréquence accrue des stress abiotiques, et une utilisation réduite de l'eau et des autres ressources. Parmi les contraintes biotiques, Savary et al. (2019) ont estimé que 21,5% des pertes de rendement actuelles sont dues aux ravageurs et aux maladies. Sur les 31 ravageurs et agents pathogènes signalés dans le blé, les maladies fongiques comme la rouille des feuilles, la fusariose de l'épi, la tache septorienne, la rouille jaune, la tache noire, la tache bronzée et l'oïdium causent les pertes les plus graves. Les maladies du blé provoquent également des altérations des propriétés chimiques et de la qualité (Gaju et al., 2014).

CHAPITRE 1
PRESENTATION DU PROJET ET ETAT DE
L'ART :

I. INTRODUCTION :

De nos jours, l'intelligence artificielle s'avère une solution intéressante face aux enjeux de l'agriculture. Elle permet à l'agriculteur de faire des économies, d'utiliser moins de produits chimiques, de prévenir les maladies de ses animaux, d'améliorer la qualité de la production de lait ou de viande, de réduire certains coûts de production etc.

Dans ce premier chapitre, nous commençons par la présentation de notre cadre du projet en précisant l'organisme d'accueil et en donnant un aperçu sur l'état de l'art ainsi que des généralités sur les technologies utilisées.

II. PRESENTATION GENERALE DU CRNS :

Le Centre de Recherche en Numérique de Sfax, a été créé en juillet 2012. Il s'agit d'un établissement public dont la mission est de mener des activités de recherche et développement dans le domaine des technologies de l'information et de la communication et de promouvoir l'innovation et le transfert de technologie dans ce domaine. Il vise à être à la pointe de la technologie en menant des recherches appliquées axées sur l'innovation. Son personnel est composé de chercheurs seniors hautement qualifiés (professeurs d'université) et de doctorants en informatique et télécommunication. Ils travaillent à élaborer des solutions sophistiquées et à développer des techniques et des outils couvrant des sujets récents comme les smart-grids, la e-santé, les transports intelligents, l'e-gouvernement, etc... Le centre de recherche en numérique de Sfax est un établissement public à caractère scientifique et technique qui avait beaucoup de partenaire académique telles que ENET'Com Sfax.



Figure 1 : Centre de recherche en numérique Sfax (CRNS)

III. PRESENTATION DU PROJET :

III.1 Contexte :

Une approche pertinente est la surveillance des champs à cultivés, ce qui permet d'identifier la maladie à un stade précoce et de prendre des mesures pour empêcher sa propagation.

III.2 Problématique :

Les maladies du blé causées par des agents pathogènes fongiques peuvent réduire considérablement le rendement des cultures.

De nombreuses cultures sont sensibles à ces maladies. Il est difficile de lutter contre ces maladies à grande échelle.

III.3 Objectifs :

On vise à appliquer une des méthodes de contrôle efficaces est l'identification de la maladie basée sur l'analyse d'images numériques avec la possibilité de les obtenir dans les conditions du terrain à l'aide de dispositifs mobiles.

Dans ce travail, nous proposons une méthode pour la reconnaissance de 3 maladies fongiques des pousses de blé (Crown & Root Rot, Leaf_rust, Wheat Loose Smut) ainsi que le cas sain nommé (Healthy).

III.4 Systèmes existants :

Il existe divers systèmes pour la classification des maladies des blés tel que :

- La surveillance manuelle des champs par les ouvriers lors de la récolte ou bien par le propriétaire lors d'une visite par hasard.
- Des solutions applications mobile intelligente basés sur l'identification des maladies à base des captures camera.

IV. ETAT DE L'ART :

III.1 Intelligence artificielle :

L'intelligence artificielle (IA) est un « ensemble de théories et de techniques mises en œuvre en vue de réaliser des machines capables de simuler l'intelligence humaine »




Figure 2 : Intelligence artificielle

III.2 Apprentissage automatique :

L'apprentissage automatique est une application de l'intelligence artificielle qui se concentre sur l'utilisation de données et d'algorithmes pour fournir aux systèmes la capacité d'apprendre et de s'améliorer d'une manière automatique à partir de l'expérience.

On peut citer trois types d'algorithmes d'apprentissage automatique :

- - Apprentissage supervisé.
- - Apprentissage non supervisé.
- - Apprentissage par renforcement.




Figure 3 : Types d'Apprentissage automatique

III.3 Apprentissage profond :

Ce type d'apprentissage est basé sur l'analogie avec le réseau neuronal humain donc la liaison entre le neurone et un réseau de neurone à une couche est un flux d'informations circulant dans le réseau.

Nous commençons par la première couche qui est la couche d'entrée qui va recevoir les données que nous disposons.

La couche finale dite couche de sortie (output layer) qui nous renseigne sur le résultat classification.

Les couches situées entre les deux couches d'entrées et sortie sont dites couches cachées. Ils représentent différentes de données pour aider le modèle à faire une classification correcte.

La densité des couches cachées donne au modèle le nom profond plus ils sont nombreux plus le modèle est profond.




Figure 4 : Architecture d'apprentissage profond

III.4 Classification des images par apprentissage profond :

III.4.1 Introduction :

La classification automatique des images consiste à attribuer automatiquement une classe à une image à l'aide d'un système de classification. On retrouve ainsi la classification d'objets, de scènes, de textures, la reconnaissance de visages, d'empreintes digitale et de caractères.

III.4.2 Définition de l'image :

Une **image** est une représentation visuelle, voire mentale, de quelque chose (objet, être vivant ou concept).

On s'intéresse aux images numériques qui représente la forme binaire des images, dans ce cas il existe 3 types principales :

- **Image RGB**, 3 couleurs sont présent Rouge, Vert, Bleu dont chacun a 256 valeurs possibles.
- **Image Grayscale**, ou image aux niveaux de gris a 256 valeurs possibles.
- **Image Binaire**, 2 valeurs sont possibles 0 ou bien 1.




Figure 5 : Types des images numériques

III.4.3 Différents types de classification des images :

Il existe deux principaux types d'apprentissage : l'apprentissage supervisé et l'apprentissage non-supervisé.

Dans l'approche supervisée, chaque image est associée à une étiquette qui décrit sa classe d'appartenance.

Dans l'approche non supervisée les données disponibles ne possèdent pas d'étiquettes. Dans notre travail on s'intéresse de l'approche supervisée.




Figure 6 : Apprentissage supervisé et non supervisé

III.4.4 Quelques méthodes de classification des images :

- **Classification à base d'un modèle CNN :**

Les réseaux de neurones convolutifs sont à ce jour les modèles les plus performants pour classer des images. Désignés par l'acronyme CNN, de l'anglais Convolution Neural Network, ils comportent deux parties bien distinctes. En entrée, une image est fournie sous la forme d'une matrice de pixels. Elle a 2 dimensions pour une image en niveaux de gris.

La couleur est représentée par une troisième dimension, de profondeur 3 pour représenter les couleurs fondamentales [Rouge, Vert, Bleu].

La première partie d'un CNN est la partie convolutive à proprement parler. Elle fonctionne comme un extracteur de caractéristiques des images. Une image est passée à travers une succession de filtres, ou noyaux de convolution, créant de nouvelles images appelées cartes de convolutions. Certains filtres intermédiaires réduisent la résolution de l'image par une opération de maximum local. Au final,

les cartes de convolutions sont mises à plat et concaténées en un vecteur de caractéristiques, appelé code CNN.

Ce code CNN en sortie de la partie convolutive est ensuite branché en entrée d'une deuxième partie, constituée de couches entièrement connectées (perceptron multicouche). Le rôle de cette partie est de combiner les caractéristiques du code CNN pour classer l'image.

La sortie est une dernière couche comportant un neurone par catégorie. Les valeurs numériques obtenues sont généralement normalisées entre 0 et 1, de somme 1, pour produire une distribution de probabilité sur les catégories.

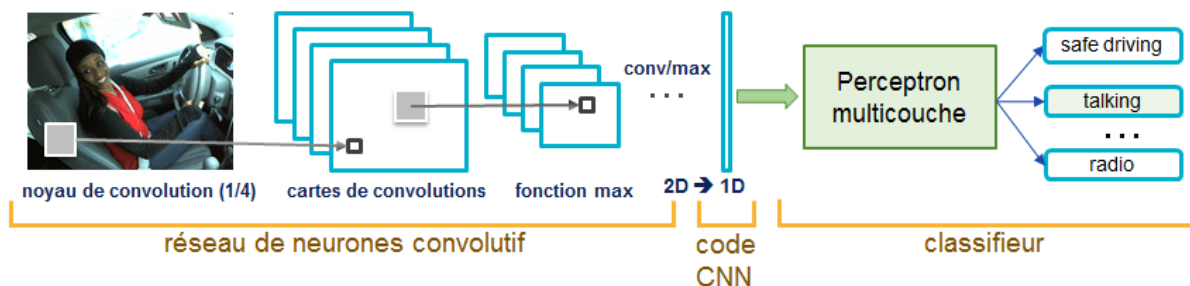


Figure 7 : Principe du modèle CNN

- **Classification à base de Transfert Learning :**

Pour des usages pratiques, il est possible d'exploiter la puissance des CNN sans être un expert du domaine, avec du matériel accessible et une quantité raisonnable de données annotées. Toute la complexité de création de CNN peut être évitée en adaptant des réseaux pré-entraînés disponibles publiquement. Ces techniques sont appelées transfert Learning, car on exploite la connaissance acquise sur un problème de classification général pour l'appliquer de nouveau à un problème particulier.

Pour notre cas on a utilisé **VGG19** comme modèle d'apprentissage.

- **VGG19 :**

VGG est un réseau de neurones convolutionnels proposés par K. Simonyan et A. Zisserman de l'université d'Oxford et qui a acquis une notoriété en gagnant la compétition **ILSVRC** (*ImageNet Large Scale Visual Recognition Challenge*) en 2014. Le modèle a atteint une précision de 92.7% sur *Imagenet* ce qui est un des meilleurs scores obtenus. Il a marqué une progression par rapport aux modèles précédents en proposant, dans les couches de convolution, **des noyaux de convolution de plus petites dimensions (3×3)** que ce qui avait

été fait jusque-là. Le modèle a été entraîné sur des semaines en utilisant des cartes graphiques de pointe.

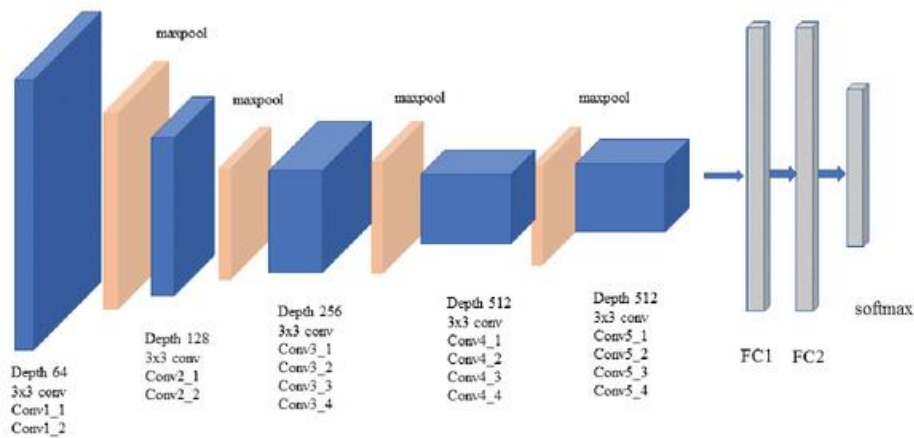


Figure 8 : Architecture VGG19

- Autre modèles pré- entraînés :

Keras offre un large choix des modèles d'apprentissage profond aux cotés des poids pré-entraînés tel que :

Xception, VGG16, ResNet50, InceptionV3, MobileNet, EfficientNetB7, ConvexNeXtSmall

III.4.5 Indicateurs de performance en classification :

•Matrice de confusion :

Prenons l'exemple d'un classifieur binaire, c'est-à-dire, qui prédit 2 classes notées classe 0 et classe 1. Pour mesurer les performances de ce classifieur, il est d'usage de distinguer 4 types d'éléments classés pour la classe voulue :

1. Vrai positif VP : Elément de la classe 1 correctement prédit.
2. Vrai négatif VN : Elément de la classe 0 correctement prédit.
3. Faux positif FP : Elément de la classe 1 mal prédit.
4. Faux négatif FN : Elément de la classe 0 mal prédit.

Ces informations peuvent être rassemblés et visualisés sous forme de tableau dans une matrice de confusion. Dans le cas d'un classifieur binaire, on obtient :

Confusion matrix		Reality	
		Negative : 0	Positive : 1
Prediction	Negative : 0	True Negative : TN	False Negative : FN
	Positive : 1	False Positive : FP	True Positive : TP

Figure 9 : Matrice de confusion

En particulier, si la matrice de confusion est diagonale, le classifieur est parfait. Notons que la matrice de confusion est aussi généralisable lorsqu'il y a $k > 2$ classes à prédire.

• Rapport de classification :

Il est possible de calculer plusieurs indicateurs résumant la matrice de confusion. Par exemple si nous souhaitons rendre compte de la qualité de la prédiction sur la classe 1, on définit :

1- **Précision** : proportion d'éléments bien classés pour une classe donnée :

$$Précision_{de\ la\ classe\ 1} = \frac{VP}{VP + FP}$$

2- **Rappel** : proportion d'éléments bien classés par rapport au nombre d'éléments de la classe à prédire :

$$Rappel_{de\ la\ classe\ 1} = \frac{VP}{VP + FN}$$

3- **F-mesure** : mesure de compromis entre précision et rappel :

$$F - mesure_{de\ la\ classe\ 1} = \frac{2 * (Précision * Rappel)}{Précision + Rappel}$$

Il est possible de calculer tous ces indicateurs pour chaque classe. La moyenne sur chaque classe de ces indicateurs donne des indicateurs globaux sur la qualité du classifieur :

$$Precision = \frac{1}{k} \sum_{i=1}^k \frac{VP_i}{VP_i + FP_i}$$

$$Rappel = \frac{1}{k} \sum_{i=1}^k \frac{VP_i}{VP_i + FN_i}$$

$$F - mesure = \frac{2 * (Précision * Rappel)}{Précision + Rappel}$$

V. CONCLUSION :

A partir de ce chapitre, nous avons pu donner une présentation du contexte de notre projet. En addition, nous avons évidemment présenté les problématiques et les objectifs visés de ce projet. L'étude de l'état de l'art et d'exemples de systèmes de classification des maladies de blés déjà existants s'est avérée indispensable dans le but de choisir les méthodes les plus performantes pour la partie de la conception du projet qui forme la base du prochain chapitre.

CHAPITRE 2

REALISATION DU PROJET :

I. INTRODUCTION :

La recherche élaborée au premier chapitre nous a conduit à la phase de mise en œuvre pour réaliser enfin la tâche de classification. Ce chapitre est dédié à évoquer les bibliothèques utilisées, l'apprentissage du modèle et les résultats obtenues.

II. BIBLIOTHEQUES UTILISEES :

II.1 Tensorflow :

TensorFlow est un outil open source d'apprentissage automatique développé par Google. Il est fondé sur l'infrastructure DistBelief, initiée par Google en 2011, et est doté d'une interface pour Python, Julia et R3TensorFlow est l'un des outils les plus utilisés en IA dans le domaine de l'apprentissage machine.



Figure 10 : Logo TensorFlow

II.2 Keras :

La bibliothèque Keras permet d'interagir avec les algorithmes de réseaux de neurones profonds et d'apprentissage automatique, notamment Tensorflow, Theano, Microsoft Cognitive Toolkit ou PlaidML.



Figure 11 : Logo Keras

II.3 Python :

Python est un langage de programmation interprété, orienté objet, de haut niveau avec une sémantique dynamique et un rendement très attrayant pour le développement d'applications rapides.

La syntaxe simple et facile à apprendre de Python met l'accent sur la lisibilité et réduit donc le coût de la maintenance du programme. Python supporte les modules et les paquets, ce qui encourage la modularité des programmes et la réutilisation du code.



Figure 12 : Logo Python

III. APPRENTISSAGE DU MODELE :

III.1 La base de données :

Un modèle de classification d'images nécessite une base de données pour s'entraîner avec et générer les résultats voulus.

Pour ce cas nous avons choisis la base de données suivantes :

Elle Comporte 4 classes comme suit :

	Classes	Nombre images
0	Crown & Root Rot	696
1	Healthy Wheat	1030
2	Leaf_rst	849
3	Wheat Loose Smut	939

Cette base de données est importée via cette source 'Large Wheat Disease Classification Dataset (LWDCD2020)' avec des changements nécessaires effectués pour améliorer la classification.

III.2 Implémentation des algorithmes d'apprentissages :

La phase d'apprentissage a été effectué sur « Google Colaboratory » qui est un raccourci en "Colab" et un produit de Google Research. Colab permet à

n'importe qui d'écrire et d'exécuter le code Python sur le bloc-notes de Colab. C'est un environnement particulièrement adapté à l'apprentissage automatique, à l'analyse de données et surtout à la formation de modèles face au manque de ressources matérielles.

En termes plus techniques, Colab est un service hébergé de notebooks Jupyter qui ne nécessite aucune configuration et qui permet d'accéder gratuitement à des ressources informatiques, dont des GPU.

Puisque collab utilise un GPU Très puissant par rapport à notre machine, nous avons fait tout l'apprentissage de modèle sur Google Colaboratory.



Figure 13 : Logo Google Colaboratory

III.3 Problèmes lors de l'apprentissage :

Durant la phase d'apprentissage du modèle nous avons affronter 2 majeurs problèmes :

- Surapprentissage « Overffiting » : C'est un problème qui se produit lorsqu'un modèle réseau neuronal profond est beaucoup plus performant pour les données d'apprentissage que pour les nouvelles données.
- Précision d'Evaluation faible : La précision au niveau de l'évaluation du modèle était médiocre à causes des données fausses présentent dans l'ensemble de base de données.




Figure 14 : Précision perturbée et faible

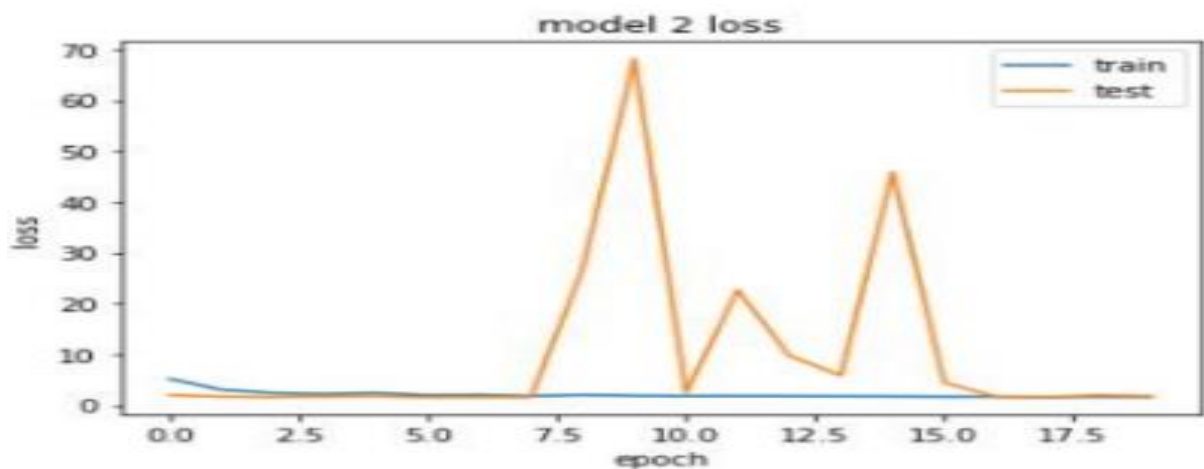


Figure 15 : Perte perturbée et faible

```
10/10 [#####] - 7s 332ms/step - loss: 1.9370 - accuracy: 0.2857
Untrained model, accuracy: 28.57%
```

Figure 16 : Précision d'évaluation faible

III.4 Augmentation des données :

L'augmentation des données d'image est peut-être la technique la plus connue d'augmentation des données. Elle regroupe les techniques utilisées pour augmenter artificiellement la taille d'un groupe de données d'apprentissage en créant des versions modifiées d'images à partir des images d'apprentissage disponibles.

Dans notre cas l'augmentation des données pour la partie entraînement du modèle a élevé notre base de données de 2108 images regroupés en 4 classes à 2614 images regroupés en 4 classes.

III.5 Impact du taux d'apprentissage :

Le taux d'apprentissage 'Learning rate' est un terme que nous utilisons dans l'apprentissage automatique, apprentissage profond et les statistiques. En bref, il fait référence à la vitesse à laquelle un algorithme converge vers une solution. Le taux d'apprentissage est l'un des hyperparamètres les plus importants pour la formation des réseaux neuronaux. Il est donc très important de définir une valeur aussi proche que possible de la valeur optimale.




Figure 17 : Explication taux d'apprentissage

III.6 Impact de la taille du lot :

La taille du lot 'batch size' définit le nombre d'échantillons utilisés dans une époque pour former un réseau neuronal. Il existe trois types de descente de gradient en fonction de la taille du lot :

- Descente de gradient par lot - utilise tous les échantillons de l'ensemble de formation en une époque.
- Descente de gradient stochastique - utilise un seul échantillon aléatoire de l'ensemble de formation en une époque.
- Descente de gradient par mini-lots - utilise un nombre prédéfini d'échantillons de l'ensemble d'apprentissage en une époque.

La taille du lot affecte certains indicateurs tels que le temps de formation global, le temps de formation par époque, la qualité du modèle, etc. Habituellement, nous choisissons la taille du lot comme une puissance de deux, dans une fourchette comprise entre 16 et 512. Mais généralement, la taille de 32 est une règle empirique et un bon choix initial.




Figure 18 : Explication taille du lot

III.7 Comparaison des modèles utilisées :

La phase d'apprentissage du modèle nous a conduit à tester des différents algorithmes pré-entraînés à fin d'en choisir le modèle qui performe le mieux dans notre cas, dans le tableau ci-dessous montre une comparaison aux niveaux paramètres et résultats obtenues :

Modèle	Précision Train	Précision Test	Précision Validation	Epochs	Batch Size
VGG19	0.84	0.79	0.82	20	32
EfficinetNet03	0.76	0.68	0.72	20	32
Resnet50	0.56	0.49	0.52	20	32

IV. RESULTAS FINALES :

IV.1 Architecture du modèle optimal :

La combinaison optimale obtenu s'est basée sur le modèle pré entraîné **VGG19** sous l'architecture suivante :

Layer (type)	Output Shape	Param #
=====		
input_1 (InputLayer)	[(None, 300, 300, 3)]	0
block1_conv1 (Conv2D)	(None, 300, 300, 64)	1792
block1_conv2 (Conv2D)	(None, 300, 300, 64)	36928
block1_pool (MaxPooling2D)	(None, 150, 150, 64)	0
block2_conv1 (Conv2D)	(None, 150, 150, 128)	73856
block2_conv2 (Conv2D)	(None, 150, 150, 128)	147584
block2_pool (MaxPooling2D)	(None, 75, 75, 128)	0
block3_conv1 (Conv2D)	(None, 75, 75, 256)	295168
block3_conv2 (Conv2D)	(None, 75, 75, 256)	590080
block3_conv3 (Conv2D)	(None, 75, 75, 256)	590080
block3_conv4 (Conv2D)	(None, 75, 75, 256)	590080
block3_pool (MaxPooling2D)	(None, 37, 37, 256)	0
block4_conv1 (Conv2D)	(None, 37, 37, 512)	1180160
block4_conv2 (Conv2D)	(None, 37, 37, 512)	2359808
block4_conv3 (Conv2D)	(None, 37, 37, 512)	2359808
block4_conv4 (Conv2D)	(None, 37, 37, 512)	2359808
block4_pool (MaxPooling2D)	(None, 18, 18, 512)	0
block5_conv1 (Conv2D)	(None, 18, 18, 512)	2359808
block5_conv2 (Conv2D)	(None, 18, 18, 512)	2359808
block5_conv3 (Conv2D)	(None, 18, 18, 512)	2359808
block5_conv4 (Conv2D)	(None, 18, 18, 512)	2359808
block5_pool (MaxPooling2D)	(None, 9, 9, 512)	0
average_pooling2d (AveragePooling2D)	(None, 1, 1, 512)	0

flatten (Flatten)	(None, 512)	0
dense (Dense)	(None, 512)	262656
dropout (Dropout)	(None, 512)	0
dense_1 (Dense)	(None, 3)	1539

Total params: 20,288,579
Trainable params: 264,195
Non-trainable params: 20,024,384

IV.2 Paramètres :

L'apprentissage du modèle s'est effectué selon les paramètres suivantes :

- 20 epochs
- Batch size = 32
- Lr = 0.01
- 60% des images pour le train, 20% pour la validation et 20% pour le test

IV.3 Courbes obtenues :

Dans cette partie je vais présenter les courbes obtenues en tant que précision et perte pour la phase d'entraînement et la phase du test pour le modèle optimal.




Figure 19 : Précision du train et test VGG19




Figure 20 : Perte du train et test VGG19

IV.4 Rapport de classification :

Dans le rapport qui suit s'illustre la qualité de précision pour notre modèle

	precision	recall	f1-score	support
0	0.84	0.76	0.80	147
1	0.81	0.79	0.80	199
2	0.84	0.83	0.84	178
3	0.79	0.89	0.83	175
accuracy			0.82	699
macro avg	0.82	0.82	0.82	699
weighted avg	0.82	0.82	0.82	699

Figure 21 : Rapport de classification VGG19

IV.5 Matrice de confusion :

Cette représentation matricielle englobe les 4 classes du modèle et nous renseigne sur le taux des prédictions correctes en nombre et en pourcentage.




Figure 22 : Matrice de confusion VGG19

V. CONCLUSION :

A travers ce chapitre, nous avons présenté les différentes bibliothèques ainsi que les étapes nécessaires pour pouvoir choisir le modèle optimal pour récolter les meilleurs résultats de classification.

CONCLUSION GENERALE ET PERESPECTIVES

L'agriculture de demain ne sera plus seulement une affaire de semis, d'engrais et d'irrigation, mais aussi d'algorithmes et de plateforme. Toute la planète sera concernée par cette transformation numérique qui envahit progressivement le continent africain et le monde entier.

Avec ce présent travail, nous avons exploité des données présentes sur terrain, des bases de données des images réelles des maladies qui peuvent attaquer les céréales notamment les blés.

Dans ce contexte, il s'avère pertinent de comprendre les répercussions liées à la mise en œuvre des solutions IA dans le domaine agricole et d'examiner la manière dont celles-ci pourraient répondre aux défis technologiques et ce dans un environnement global affecté, entre autres, par le changement climatique. Ces technologies basées sur l'IA peuvent aider le secteur agricole à produire de meilleures récoltes et à améliorer un large éventail de tâches liées à l'agriculture dans l'ensemble de la chaîne d'approvisionnement alimentaire. Ces nouvelles méthodes ont permis d'augmenter les besoins alimentaires et ont également fourni des opportunités d'emploi à des milliards de personnes dans tout le système. L'utilisation de l'IA dans l'agriculture a révolutionné l'agriculture et a défendu le rendement des cultures contre plusieurs facteurs tels que la croissance démographique, les changements climatiques, les problèmes d'emploi et les problèmes de sécurité alimentaire.

Toutefois, il faut toujours bien préciser l'étude élaborée pour n'importe quel projet en utilisant les technologies basées sur l'intelligence artificielle en spécifiant les besoins nécessaires car une telle implémentation coûte de l'argent et un mal fonctionnement peut causer des pertes énormes.

BIBLIOGRAPHIE

<http://www.crns.rnrt.tn/>

<https://www.frontiersin.org/articles/10.3389/fpls.2021.671060/full>

<https://www.intechopen.com/online-first/80489>

<https://www.futura-sciences.com/tech/definitions/informatique-intelligence-artificielle-555/>

<https://www.stemmer-imaging.com/fr-ch/conseil-technique/apprentissage-automatique-et-apprentissage-profond/>

[https://www.schoolmouv.fr/definitions/image-numerique/definition#:~:text=Une%20image%20num%C3%A9rique%20est%20une,de%20bleu%20\(codage%20RVB\)](https://www.schoolmouv.fr/definitions/image-numerique/definition#:~:text=Une%20image%20num%C3%A9rique%20est%20une,de%20bleu%20(codage%20RVB))

<https://datascientest.com/convolutional-neural-network>

<https://keras.io/api/applications/vgg/>

https://fr.wikipedia.org/wiki/Matrice_de_confusion

<https://openclassrooms.com/fr/courses/4297211-evaluez-les-performances-dun-modele-de-machine-learning/4308256-evaluez-un-algorithme-de-classification-qui-retourne-des-valeurs-binaires>

<https://www.tensorflow.org/resources/>

<https://machinelearningmastery.com/understand-the-dynamics-of-learning-rate-on-deep-learning-neural-networks/>

<https://stats.stackexchange.com/questions/153531/what-is-batch-size-in-neural-network>

<https://colab.research.google.com/>

<https://datascientest.com/apprentissage-non-supervise>

<https://blog.techcraft.org/vgg-19-convolutional-neural-network/>